

Relatório Final – Projeto de Data Science

Disciplina: Data Science

Professor: Dr. Carlos Amaral Hölbíg

Alunos: Romeu Maia (120206), Bernardo Zaparoli (189797), Guilherme Di Domenico (188997)

Tema do Projeto

Previsão de Temperatura Aparente a partir de Variáveis Climáticas

Este trabalho visa desenvolver um modelo de Machine Learning para estimar a **sensação térmica** (Apparent Temperature) com base em dados meteorológicos históricos.

Estrutura de Pastas

```
trab-final-data-science/
|
├── Data/
│   ├── weatherHistory.csv          # Dataset original (.csv)
│   └── weatherHistory_clean.csv    # Versão limpa após pré-processamento
|
├── env/                            # Ambiente virtual (opcional)
|
├── Scripts/
│   ├── limpeza.py                 # Funções de carregamento e limpeza de
dados                               dados
│   ├── analize.py                 # Funções de EDA e visualizações de
dados                               dados
│   └── modelagem.py               # Preparação de features e avaliação de
modelos                             modelos
|
├── .gitignore                     # Padrões de arquivos/pastas ignorados
pelo Git
└── WeatherHistoryNotebook.ipynb   # Notebook autônomo com todo o pipeline
```

Dataset

- **Origem:**
Kaggle – [muthuj7/weather-dataset](https://www.kaggle.com/muthuj7/weather-dataset)
Conjunto de dados históricos de Szeged, Hungria (2006–2016), com ~96.000 registros.
 - **Variáveis principais:**
 - Formatted Date (data e hora UTC)
 - Temperature (C), Apparent Temperature (C)
 - Humidity, Wind Speed (km/h), Visibility (km), Pressure (millibars)
 - Summary, Precip Type
 - **Pré-processamento realizado:**
 1. Parse da coluna de datas para datetime e conversão para UTC.
 2. Remoção de colunas irrelevantes: Loud Cover, Daily Summary.
 3. Tratamento de valores faltantes em Precip Type (preenchimento com 'none').
 4. Remoção de duplicatas e registros sem data.
 5. Salvamento do arquivo limpo (weatherHistory_clean.csv).
 - **Registros após limpeza:** 96.429 linhas.
-





Limpeza e Análise Exploratória

Estatísticas Descritivas


- A temperatura real e a aparente apresentam alta correlação (~0,99), indicando forte relação linear.
- A umidade também mostra correlação relevante com a temperatura aparente (~0,65).

Distribuições

- **Temperature (C) - Apparent Temperature (C)**




- Diferença (Apparent - Real)




Categóricas

- Contagem por Precip Type




- Top 10 Summaries




Séries Temporais

- Temp Aparente (Média Diária)




- Temp Aparente (Média Mensal)




Sazonalidade

- Temp Aparente por Mês




- Temp Aparente por Hora do Dia



Correlação

- Matriz de Correlação



Modelagem Preditiva

Foram treinados dois modelos para prever `Apparent Temperature (C)`:

Modelo	R ² (teste)	RMSE (teste)
Regressão Linear	0,990	1.07°C
Random Forest	0.999	0.11 °C

- Regressão Linear:** baseline que captura relações lineares.
- Random Forest (20 árvores, profundidade 10):** melhor desempenho ao modelar não-linearidades.

Conclusões

- O pipeline completo de Data Science foi implementado (coleta, limpeza, EDA, modelagem e avaliação).

2. A previsão de temperatura aparente alcançou excelente acurácia (~99% da variância explicada).

3. Variáveis mais relevantes: `Temperature (C)` e `Humidity`.

Próximos passos:

- Otimização de hiperparâmetros (GridSearch, RandomizedSearch).
- Teste de algoritmos de boosting (XGBoost, LightGBM).
- Criação de features de data/hora (estações, ciclos diários).

Repositório GitHub

<https://github.com/ZapinhaCode/trab-final-data-science>

Ferramentas e Tecnologias

- Python 3.x
- Pandas, Matplotlib, Seaborn
- Scikit-learn
- Jupyter Notebook
- Obsidian